PROJETO PRÁTICO – CHECK POINT 2

APRENDIZADO PROFUNDO CONVOLUCIONAL COM REDES NEURAIS CONVOLUCIONAIS

Classificação binária de imagens: preparação, fluxo interno e interpretação de uma CNN

Integrantes (nome completo e RM):	Turma:
Data de entrega:	Valor: 10 pontos

1. CONTEXTO DO PROJETO

Neste Check Point, os alunos deverão aplicar os conceitos de processamento de imagens e redes neurais convolucionais em um problema simples de classificação binária de imagens. O foco será compreender o caminho percorrido pela imagem: preparação do dado, representação como tensor, transformação por camadas convolucionais e geração da predição final.

Diferentemente da Sprint 4, este trabalho não é uma investigação experimental de arquiteturas. Não será necessário comparar vários modelos, testar combinações de filtros ou selecionar a melhor arquitetura. O objetivo é construir uma única CNN simples, acompanhar as transformações produzidas pelas camadas e interpretar o comportamento do modelo.

2. OBJETIVO GERAL

Construir e treinar uma CNN simples para classificação binária de imagens, demonstrando compreensão sobre preparação de imagens, tensores, Conv2D, funções de ativação e diferentes formas de organizar uma arquitetura convolucional, incluindo operações como MaxPooling2D e a transformação dos mapas de características por GlobalAveragePooling2D ou Flatten antes da classificação.

3. ESCOPO E ESCOLHA DA BASE DE IMAGENS

A base de imagens deverá ser escolhida pelo aluno ou grupo, com tema livre. O objetivo é permitir que cada grupo trabalhe com um problema de seu interesse, desde que o conjunto escolhido seja adequado a uma classificação binária simples e permita concluir a atividade no tempo disponível. A base deverá atender aos seguintes requisitos:

- possuir exatamente duas classes de imagens;
- já possuir rótulos de classe, sem exigir anotação manual de bounding boxes ou máscaras;
- ter origem identificável e permitir informar a fonte dos dados;
- possuir quantidade de imagens suficiente para separar treino, validação e teste;
- ser pequena ou moderada o suficiente para permitir treinamento em Google Colab ou ambiente equivalente;
- não exigir detecção de objetos, segmentação, transfer learning ou modelos pré-treinados.

O grupo deve informar a fonte da base, justificar brevemente a escolha do tema, apresentar as duas classes, a quantidade de imagens por classe e exemplos visuais do conjunto utilizado.

4. ETAPAS OBRIGATÓRIAS

4.1 Inspeção das imagens

- Informar a quantidade total de imagens e a distribuição entre as duas classes.
- Exibir pelo menos 3 exemplos de cada classe.
- Inspecionar pelo menos uma imagem e apresentar shape, dtype, valor mínimo e valor máximo dos pixels.
- Explicar, com base no exemplo utilizado, o significado de altura, largura e canais no tensor H × W × C.

4.2 Preparação dos dados

- Separar os dados em treino, validação e teste antes da avaliação final.
- Redimensionar todas as imagens para um tamanho fixo adequado à CNN, como 128 × 128 pixels.
- Normalizar os pixels para a faixa de 0 a 1.
- Aplicar exatamente o mesmo redimensionamento e normalização em treino, validação e teste.

- Data augmentation é opcional. Se utilizado, deve ser aplicado apenas ao conjunto de treino e deve gerar imagens plausíveis para o problema.

4.3 Demonstração de uma operação de convolução

Antes do treinamento da CNN, o grupo deverá escolher uma imagem da base e aplicar um filtro 3 × 3 simples, definido manualmente, para evidenciar uma transformação local da imagem. Pode ser utilizado, por exemplo, um kernel de detecção de bordas ou realce.

- Exibir a imagem original e o resultado produzido pelo filtro.
- Informar o kernel utilizado.
- Explicar brevemente o que mudou na imagem e relacionar o resultado ao conceito de mapa de características.

4.4 Definição e construção da CNN

O trabalho deverá utilizar uma única arquitetura de CNN, definida pelo próprio grupo. Não existe uma arquitetura obrigatória nem uma sequência fixa de camadas. O grupo deverá montar uma arquitetura coerente com o problema e explicar a função dos componentes escolhidos. Podem ser utilizados, por exemplo, Conv2D, MaxPooling2D, GlobalAveragePooling2D, Flatten e Dense, combinados de acordo com a proposta do grupo. Não é necessário utilizar todos os componentes apresentados, e GlobalAveragePooling2D e Flatten podem ser tratados como alternativas para transformar os mapas de características em uma representação adequada à etapa de classificação.

Componente	Configurações / possibilidades	Papel na arquitetura
Input	Shape compatível com o resize e o número de canais	Definir o formato do tensor de entrada
Conv2D	filters, kernel_size, padding, strides e activation	Extrair padrões locais e produzir mapas de características
MaxPooling2D	pool_size e strides, quando necessário	Reduzir as dimensões espaciais dos mapas
GlobalAveragePooling2D	Sem necessidade de tamanho fixo de vetor	Resumir cada mapa de características em um valor
Flatten	Transforma H × W × C em um vetor	Alternativa ao GAP para conectar mapas à rede densa
Dense	Quantidade de neurônios e função de ativação	Combinar características e realizar a classificação
Saída binária	1 neurônio com sigmoid	Produzir a probabilidade da classe positiva

4.5 Previsão e conferência dos shapes

Antes de executar o model.summary(), o grupo deverá prever o shape de saída das principais camadas da arquitetura que definiu e, depois, conferir os valores com o modelo construído. O objetivo é demonstrar compreensão sobre como filtros, kernel, padding, stride, pooling e a estratégia escolhida para transformar os mapas de características em vetor afetam o tensor. A tabela deverá ser adaptada com mais ou menos linhas conforme a arquitetura utilizada.

Etapa / camada	Shape esperado	Shape obtido	Interpretação
Entrada			
Camada / bloco 1			
Camada / bloco 2			
Camada / bloco 3			
Camada / bloco 4			
Representação antes da saída (GAP ou Flatten, se utilizado)			

4.6 Treinamento

- Compilar o modelo com função de perda adequada à classificação binária e otimizador compatível.
- Treinar a CNN uma única vez utilizando os conjuntos de treino e validação.
- Registrar o número de épocas e o batch size utilizados.
- Apresentar as curvas de loss e acurácia de treino e validação.
- Comentar se as curvas sugerem aprendizado adequado, underfitting ou overfitting.

Não é necessário realizar busca de hiperparâmetros, repetir o treinamento com outras arquiteturas ou selecionar um "melhor modelo".

4.7 Avaliação no conjunto de teste

Após o treinamento, avaliar a única CNN no conjunto de teste. Apresentar, no mínimo:

- acurácia;
- precisão;
- recall;
- F1-score;
- matriz de confusão;
- pelo menos 6 exemplos de predições com classe real, classe prevista e probabilidade.

5. ROTEIRO MÍNIMO DE EVIDÊNCIAS

O notebook deverá deixar visível, de forma objetiva, cada evidência abaixo:

Etapa	Evidência mínima	O que deve ser explicado
Dados	6 imagens de exemplo + contagem por classe	O que cada classe representa
Tensor	shape, dtype, mínimo e máximo	Como a imagem é representada numericamente
Pré-processamento	imagem antes/depois do resize e normalização	Por que o modelo precisa de entrada padronizada
Convolução	kernel 3 × 3 + mapa resultante	Qual padrão local o filtro evidencia
CNN	model.summary() + tabela de shapes	Como o tensor muda entre as camadas
Treino/Teste	curvas + métricas + matriz de confusão	Como interpretar o comportamento final

6. QUESTÕES QUE DEVEM SER RESPONDIDAS NO NOTEBOOK

1. O que significa o shape H × W × C de uma imagem RGB?
2. Por que as imagens foram redimensionadas para um tamanho fixo e normalizadas?
3. O que o filtro 3 × 3 aplicado manualmente destacou na imagem?
4. Como o número de filtros de uma Conv2D aparece no shape de saída?
5. Como as camadas escolhidas alteraram altura, largura e número de canais ao longo da CNN? Destaque o papel do pooling, caso tenha sido utilizado.
6. Como o modelo transformou os mapas de características em uma representação adequada para a camada de saída? Explique o papel de GlobalAveragePooling2D ou Flatten, conforme a opção utilizada.
7. As curvas de treino e validação indicam underfitting, overfitting ou comportamento adequado? Justifique.
8. Quais tipos de erro apareceram no conjunto de teste e qual melhoria poderia ser investigada em uma etapa futura? A melhoria deve ser apenas proposta, não implementada.

7. ORGANIZAÇÃO DOS GRUPOS E SUBMISSÃO

- O trabalho poderá ser realizado individualmente ou em grupos de até 3 integrantes.
- A identificação de todos os integrantes deverá aparecer no início do notebook, com nome completo e RM/identificação acadêmica.
- Apenas um integrante do grupo deverá realizar a submissão no Microsoft Teams.
- Não é necessário produzir apresentação ou relatório técnico separado.

8. ENTREGÁVEL

Deverá ser submetido no Microsoft Teams somente um Notebook Jupyter/Google Colab (.ipynb), executável do início ao fim e organizado com células Markdown explicativas. O notebook deve conter a fonte dos dados, preparação das imagens, demonstração da convolução, construção da CNN, tabela de shapes, treinamento, avaliação e respostas às questões da Seção 6.

O foco é a compreensão do fluxo de uma CNN simples. Não é necessário desenvolver interface, API, aplicação web, comparação entre arquiteturas, detecção de objetos ou segmentação.

9. ESTRUTURA OBRIGATÓRIA DO NOTEBOOK

9.1 Identificação - título do projeto, turma, nome completo e RM de todos os integrantes.

9.2 Problema e base de imagens - fonte, classes, quantidade de imagens e exemplos visuais.

9.3 Inspeção e preparação - shape, dtype, escala dos pixels, resize, normalização e divisão dos dados.

9.4 Convolução demonstrativa - kernel 3 × 3, imagem resultante e interpretação.

9.5 Arquitetura da CNN - código do modelo, justificativa das camadas escolhidas, model.summary() e tabela de shapes previstos/obtidos.

9.6 Treinamento - configurações usadas e curvas de treino/validação.

9.7 Avaliação - métricas, matriz de confusão e exemplos de predições.

9.8 Respostas conceituais e conclusão - respostas da Seção 6 e síntese do que foi aprendido.

10. CRITÉRIOS DE AVALIAÇÃO

Critério	O que será observado	Pontos
Entendimento e preparação das imagens	Classes, inspeção do tensor, resize, normalização e organização correta dos conjuntos.	2,0
Compreensão da convolução	Kernel 3 × 3, mapa resultante e explicação coerente do padrão evidenciado.	1,5

Critério	O que será observado	Pontos
Construção e leitura da CNN	Definição coerente da arquitetura, uso correto de Conv2D e dos demais componentes escolhidos (como pooling, GAP ou Flatten e Dense), model.summary() e interpretação dos shapes.	2,5
Treinamento e diagnóstico	Execução do treinamento e interpretação das curvas de treino e validação.	1,5
Avaliação no teste	Métricas solicitadas, matriz de confusão e exemplos de predições.	1,5
Clareza e reprodutibilidade	Notebook organizado, executável e respostas conceituais claras.	1,0

11. REGRAS IMPORTANTES

- O Check Point utiliza uma única CNN; não é necessário comparar arquiteturas.
- O conjunto de teste deve ser usado somente na avaliação final.
- O mesmo padrão de resize e normalização deve ser mantido entre treino, validação e teste.
- Data augmentation, quando utilizado, deve ser aplicado apenas ao treino.
- Não é necessário utilizar transfer learning, redes pré-treinadas, detecção ou segmentação.
- O código deve ser executável e os resultados apresentados devem ser gerados pelo próprio notebook.

12. RESULTADO ESPERADO

Ao final do projeto, o aluno deverá ser capaz de explicar como uma imagem é preparada e representada como tensor, como uma CNN transforma esse tensor por meio de convoluções e demais operações escolhidas na arquitetura, como os mapas de características são convertidos em uma representação para a saída e como avaliar, de forma básica, o comportamento do classificador em dados não utilizados no treinamento.